
IF29 – Traitement de Données

Dataset : Tweet_Worldcup.zip – Coupe du Monde 2018

Réalisé par : Mariem LANOUAR

Malcolm ARIDORY

Gwendal RODRIGUES

Mohamed BEN ABDALLAH

Juin 2026

COMPARAISON DE DEUX MÉTHODES DE CLASSIFICATION DE PROFILS de X (ex. Twitter)

Humain vs Bot



PLAN

01

PROBLÉMATIQUE

Contexte scientifique et deux approches comparées

02

PIPELINE ETL

Architecture, features et labellisation manuelle

03

ANALYSE EXPLORATOIRE

420 profils labellisés — 8 visualisations

04

MODÉLISATION

Random Forest, SVM et K-Means

05

APPRENTISSAGES

Retour d'expérience et perspectives

01

01

PROBLÉMATIQUE

Distinguer automatiquement humain vs bot sur Twitter

CONTEXTE & APPROCHES

CONTEXTE SCIENTIFIQUE

- -15% comptes Twitter = bots (Ferrara 2016)
- Taxonomie : humain / bot / cyborg (Chu 2012)
- Framework SPOT (Perez 2011)
- Enjeux : spam, astroturfing, biais d'opinion

DEUX APPROCHES

- **Supervisée** : Random Forest + SVM
420 profils annotés manuellement
- **Non supervisée** : K-Means clustering
Groupes naturels, interprétation a posteriori

4,5M tweets · 1,8M users uniques · -420 profils labellisés

02

02

PIPELINE ETL

De la donnée brute aux features analytiques

SOURCE → EXTRACT → LOAD

JSON brut (API Twitter)

```
{
  "created_date": "2018-06-14
04:23:53",
  "current_time": 1528943033156,
  "extended_entities": {
    "media": [
      {
        "media_url": "http://pbs.twimg.com/media/DfniuElXcAA2ocj.jpg",
        "source_size": {
          "w": 660,
          "h": 346,
          "resize": "fit"
        },
        "large": {
          "w": 660,
          "h": 346,
          "resize": "fit"
        },
        "expanded_url": "https://twitter.com/Stars_Traveller/status/1007085274055282688",
        "media_url_https": "https://pbs.twimg.com/media/DfniuElXcAA2ocj.jpg",
        "id": 1007085274055282688,
        "to_status_id": null,
        "created_at": "Thu Jun 14 02:23:52 +0000 2018",
        "text": "\>Twitter for iPad\n/a>",
        "retweeted_status": {
          "extended_entities": {
            "media": [
              {
                "display_url": "https://pbs.twimg.com/media/DfniuElXcAA2ocj.jpg",
                "large": {
                  "w": 660,
                  "h": 346,
                  "resize": "fit"
                },
                "thumb": {
                  "w": 150,
                  "h": 150,
                  "resize": "crop"
                },
                "expanded_url": "https://twitter.com/Stars_Traveller/status/1007085274055282688",
                "type": "photo",
                "media_url": "http://pbs.twimg.com/media/DfniuElXcAA2ocj.jpg",
                "status_id": null,
                "created_at": "Thu Jun 14 02:20:14 +0000 2018",
                "in_reply_to_status_id": null,
                "in_reply_to_user_id": null,
                "favorite_count": 1,
                "id": 1007085274055282688,
                "urls": [
                  {
                    "display_url": "goo.gl/BbEkTR",
                    "indices": [42, 65],
                    "text": "WorldCup"
                  }
                ],
                "media": [
                  {
                    "display_url": "pic.twitter.com/R89923G0Y0",
                    "large": {
                      "w": 660,
                      "h": 346,
                      "resize": "fit"
                    },
                    "thumb": {
                      "w": 150,
                      "h": 150,
                      "resize": "crop"
                    },
                    "medium": {
                      "w": 660,
                      "h": 346,
                      "resize": "fit"
                    },
                    "expanded_url": "https://twitter.com/Stars_Traveller/status/1007085274055282688/photo/1",
                    "media_url_https": "https://pbs.twimg.com/media/DfniuElXcAA2ocj.jpg"
                  }
                ]
              }
            ]
          },
          "text": "\>Twitter for iPad\n/a>",
          "retweeted_status": null,
          "retweet_count": 2,
          "retweeted": false,
          "geo": null,
          "filter_level": "high",
          "in_reply_to_status_id": null,
          "in_reply_to_user_id": null,
          "favorite_count": 1,
          "id": 1007085274055282688,
          "urls": [
            {
              "display_url": "https://t.co/R89923G0Y0",
              "indices": [0, 23],
              "text": "https://t.co/R89923G0Y0"
            }
          ],
          "place": null,
          "lang": "en",
          "quote_count": 0,
          "entities": {
            "urls": [
              {
                "display_url": "goo.gl/BbEkTR",
                "indices": [42, 65],
                "text": "WorldCup"
              }
            ],
            "media": [
              {
                "display_url": "pic.twitter.com/R89923G0Y0",
                "large": {
                  "w": 660,
                  "h": 346,
                  "resize": "fit"
                },
                "thumb": {
                  "w": 150,
                  "h": 150,
                  "resize": "crop"
                },
                "medium": {
                  "w": 660,
                  "h": 346,
                  "resize": "fit"
                },
                "expanded_url": "https://twitter.com/Stars_Traveller/status/1007085274055282688/photo/1",
                "media_url_https": "https://pbs.twimg.com/media/DfniuElXcAA2ocj.jpg"
              }
            ]
          }
        },
        "retweet_count": 2,
        "retweeted": false,
        "geo": null,
        "filter_level": "high",
        "in_reply_to_status_id": null,
        "in_reply_to_user_id": null,
        "favorite_count": 1,
        "id": 1007085274055282688,
        "urls": [
          {
            "display_url": "https://t.co/R89923G0Y0",
            "indices": [0, 23],
            "text": "https://t.co/R89923G0Y0"
          }
        ],
        "place": null,
        "lang": "en",
        "quote_count": 0,
        "entities": {
          "urls": [
            {
              "display_url": "goo.gl/BbEkTR",
              "indices": [42, 65],
              "text": "WorldCup"
            }
          ],
          "media": [
            {
              "display_url": "pic.twitter.com/R89923G0Y0",
              "large": {
                "w": 660,
                "h": 346,
                "resize": "fit"
              },
              "thumb": {
                "w": 150,
                "h": 150,
                "resize": "crop"
              },
              "medium": {
                "w": 660,
                "h": 346,
                "resize": "fit"
              },
              "expanded_url": "https://twitter.com/Stars_Traveller/status/1007085274055282688/photo/1",
              "media_url_https": "https://pbs.twimg.com/media/DfniuElXcAA2ocj.jpg"
            }
          ]
        }
      }
    ]
  }
}
```

ingest.py

batches 2000, idempotent

Table tweets (JSONB)

tweet_text	{ } raw_data
świetnie zorganizowany w de	{"id": 10076059
test The Rupert Stafford Dail	{"id": 10076059
24PT: Marcador permanece	{"id": 10076059
ChivaZ71: a whole lotta Mexi	{"id": 10076059
gal - spain ❤️🇵🇹#WorldCup #V	{"id": 10076059
ay need more muscle in the	{"id": 10076059
defooty: I have two official #	{"id": 10076059

extract_users.py

DISTINCT ON, curseur serveur

Table users (profils dédupliqués)

	123 user_id	A-Z scr
1	96 488 040	wannu
2	96 488 655	sarah_s
3	96 489 626	MadiO
4	96 490 133	daigoB
5	96 490 550	41brto

load_users.py

upsert 50K, checkpoint pickle

PostgreSQL + JSONB (vs MongoDB) – flexibilité NoSQL + puissance SQL · -20-25 min d'extraction totale

FEATURES & LABELLISATION

40+ FEATURES — 3 FAMILLES

- User-based profil
- followers, friends, verified, bio, location
- Activity-based comportement
- freq. tweet, retweet rate, âge compte
- Content-based texte
- URLs/tweet, hashtags, mentions, sources
- Sources bots détectées via LLM (Kimi K2.6)

LABELLISATION MANUELLE

420 / 1000

profils labellisés (échantillon MD5 reproductible)

- Critères (littérature) :
- default_profile + default_image
 - friends/followers > 5
 - > 50 tweets/jour
 - URLs massives, contenu dupliqué

Vue matérialisée SQL user_features — calculées en base pour performance et reproductibilité


03

03

ANALYSE EXPLORATOIRE


420 profils labellisés — patterns discriminants

DISTRIBUTION & FEATURES



348 humains · 72 bots


Déséquilibre 83% / 17%




listed: 41,5 vs 1,3 · âge: 2105j vs 247j · followers: 6092 vs 864

Humains plus établis, plus listés, plus suivis

CORRÉLATIONS & SCORES SPOT




CORRÉLATIONS & SCORES SPOT




Aggressiveness : bots 3,6× plus agressifs
Danger contre-intuitif (proxy sur 5 tweets seulement)

GRAPHE SOCIAL & ENGAGEMENT




Bots : friends élevés, followers faibles
Asymétrie du graphe social




Bots publient plus qu'ils ne likent
Engagement unidirectionnel vs bidirectionnel

ACTIVITÉ & PERSONNALISATION



Médiane : Bot 26 vs Humain 6,8 tweets/jour
Contre-intuitif – biais d'âge (comptes bots récents)



Bio : Humain 46,2% vs Bot 90,8%
Personnalisation du profil = signal discriminant fort

04

04

MODÉLISATION

Trois approches comparées

RANDOM FOREST · SVM · K-MEANS

RANDOM FOREST

MODÈLE PRINCIPAL

- Feature importance native
- Robust aux outliers
- Gère déséquilibre

Pipeline :
features → imputation →
RF + CV stratifiée

SVM (PCA)

ALTERNATIF

- Réduction PCA (95% var.)
- Noyau RBF
- class_weight="balanced"

Pipeline :
imputation → RobustScaler →
PCA → SVC

K-MEANS

NON SUPERVISÉ

- Découverte groupes naturels
- Pas de labels requis
- Interprétation a posteriori

Pipeline :
standardisation → PCA 2D →
K-Means (elbow curve)

RÉSULTATS — À COMPLÉTER

TEMPLATES — Insérer les graphiques après exécution des scripts de modélisation

RF — Feature Importance
bar chart horizontal trié

RF — Matrice de Confusion
precision / recall / F1

PCA — Variance Expliquée
scree plot cumulé

SVM — Matrice de Confusion
comparaison avec RF

K-Means — Courbe du Coude
elbow curve k=2..10

K-Means — Projection 2D
PCA clusters vs labels réels

SYNTHÈSE COMPARATIVE

Critère	Random Forest	SVM (PCA+SVC)	K-Means
Type	Supervisé	Supervisé	Non supervisé
Performance	— (à compléter)	— (à compléter)	— (à compléter)
Interprétabilité	Élevée (feature importance)	Faible (marges + PCA)	Moyenne (clusters a posteriori)
Dépendance labels	Oui (420 profils)	Oui (420 profils)	Non
Avantage clé	Feature importance native	Bonne séparation en PCA	Découvre types inconnus

Choix dépend du cas d'usage : RF si labels disponibles (interprétabilité) · K-Means pour découvrir de nouveaux types de comptes atypiques

05

05

APPRENTISSAGES

Retour d'expérience et perspectives

LIMITES & PERSPECTIVES

LIMITES

- **420 profils** sur 1,8M (taille réduite)
- **Subjectivité** de l'annotation manuelle
- **Fenêtre temporelle** : Mondial 2018 uniquement
- **Déséquilibre** 83% / 17% humain/bot

PERSPECTIVES

- **SPOT danger** : classification URLs
- **Orchestration** : Airflow / dbt
- **API** classification temps réel
- **MLOps** : drift, réentraînement

MERCI

Questions ?

Références : [1] Ferrara et al. (2016) — [2] Chu et al. (2012) — [3] Perez et al. (2011) SPOT